

Aplicación del aprendizaje profundo en la predicción de series de tiempo del recaudo: Caso de estudio en el distrito de Medellín

Julián Alberto Uribe Gómez
Julian.uribe3@udea.edu.co

Resumen

Se analiza la aplicación de técnicas de aprendizaje profundo para la predicción de series de tiempo del recaudo tributario web en Medellín entre 2018 y 2023. Se utilizó un conjunto de 44682 datos provenientes de la Subsecretaría de Tesorería, aplicando modelos de redes neuronales y métricas MAPE y RMSE para evaluar precisión y robustez de los modelos. Los resultados preliminares evidencian dependencia temporal de corto plazo y una base potencial de datos para la aplicación de los modelos, con el fin de apoyar la asignación eficiente de recursos, mejorar la gestión tributaria y fortalecer las decisiones administrativas basada en datos.

Palabras clave: aprendizaje profundo, recaudo tributario, series de tiempo, predicción

Contexto de aplicación

El recaudo de impuestos es el proceso gubernamental de obtener ingresos de los contribuyentes para financiar los servicios y proyectos públicos de orden nacional, departamental y municipal, constituyendo un componente vital de la gobernanza económica (Varshney, 2025). Por esta razón, predecir el recaudo de impuestos es crucial para optimizar la asignación de recursos públicos, prevenir incumplimientos fiscales y maximizar los ingresos gubernamentales mediante intervenciones focalizadas y una mayor eficiencia administrativa.

La evidencia es sólida a lo largo de múltiples estudios y metodologías. Tres estudios entre 2021 y 2024 demuestran de manera consistente el valor de los sistemas de predicción tributaria y como los enfoques de aprendizaje automático, superan de manera consistente a los métodos tradicionales en múltiples estudios. (Abedin et al., 2021) (Battiston et al., 2024) (David & Wasesa, 2022). Chang et al. (2020) aportan evidencia cuantitativa de que los países con mayor fortaleza operativa en la administración tributaria recaudan 3.25% más del producto interno bruto en ingresos fiscales. Las implicaciones de política incluyen una mejor asignación de recursos para auditorías, intervención temprana ante posibles incumplidores, gestión mejorada del riesgo de cumplimiento y toma de decisiones basada en datos que puede incrementar sustancialmente los ingresos mientras promueve una tributación equitativa (Battiston et al., 2024).

Objetivo

Desarrollar y evaluar un modelo basado en técnicas de aprendizaje profundo para la predicción de series de tiempo del recaudo tributario en el distrito de Medellín, con el fin de optimizar la asignación de recursos públicos y apoyar la toma de decisiones orientadas a incrementar la eficiencia en la administración tributaria.

Metodología

La tabla 1 presenta los detalles sobre el conjunto de datos de estudio. Para predecir el recaudo web mediante modelos de aprendizaje profundo y redes neuronales se procesó un conjunto de 44682 datos agrupados por fechas y horas desde el año 2018 al 2023. Dicha información pertenece a la Secretaria de Hacienda de Medellín, quienes disponen de la información a través de sus sistemas de información.

Tabla 1. Detalles del dataset de recaudo. Elaboración autor:

Variables	1. Fecha_Hora (año-mes-día Hora) 2. Valor Pago
Tipo de datos	1. Fecha_Hora: datetime 2. Valor Pago: float64
Número de datos	44682 registros
Espacio temporal	Enero 2018 – Diciembre 2023
Tamaño en disco	1.4 MB
Formato	Comma Separated Values (.csv)
Categoría	Transacciones web
Fuente de datos	Secretaria de hacienda – Subsecretaria de tesorería Alcaldía de Medellín
Método	Modelos de redes neuronales

Resultados previos

Las investigaciones actuales en predicción de series de tiempo destacan la limitada capacidad de los modelos econométricos tradicionales, como ARIMA, para capturar fenómenos de no linealidad y volatilidad de algunos conjuntos de datos, en especial los financieros. Para superar estas limitaciones, se han explorado técnicas de inteligencia artificial, en particular redes neuronales recurrentes (RNN) y perceptrones multicapa (MLP), en conjunto con métodos como los bosques aleatorios (RF).

Charef (2024) analizó los tipos de cambio USD/NOK y USD/EUR (con espacio de tiempo desde 2017 a 2022, 1305 observaciones), comparando redes MLP y RNN mediante el Error Cuadrático Medio (MSE). Los resultados confirmaron que las RNN ofrecieron mayor precisión y robustez. Por su parte, Wang et al. (2025) evaluaron la rentabilidad de los bonos del Tesoro de EE. UU. a 10 años empleando regresión lineal, árbol de decisión, bosque aleatorio y MLP. Con métricas como MSE, MAE y R^2 , el bosque aleatorio fue el modelo más exacto, logrando $R^2 = 0,576$ y confirmando la eficacia de los enfoques de aprendizaje de máquina en macrofinanzas.

En el ámbito del mercado cambiario, Abouzaid & Boussedra (2025) usaron datos mensuales del EUR/USD (con espacio de tiempo desde 2014 a 2024, 120 observaciones) junto con variables macroeconómicas. Compararon MLP, bosque aleatorio y LSTM, mostrando que este último alcanzó la mejor precisión ($R^2 = 0,9234$). Sin embargo, las variables macroeconómicas aportaron escaso valor explicativo para los errores de predicción.

Por otro lado, Inzirillo (2024) analizó el mercado de criptoactivos y propuso un enfoque híbrido que combina modelos de espacio de estados y arquitecturas RNN (LSTM y GRU), lo cual mejoró la adaptabilidad a regímenes de mercado volátiles. Finalmente, Zou et al. (2024) aplicaron RNN a la predicción de emisiones, demostrando que las LSTM superan ampliamente a ARIMA y al suavizado exponencial.

Finalmente, los estudios concluyen que las RNN, en especial las LSTM, superan a modelos clásicos y redes superficiales, mientras que los métodos de aprendizaje de máquina siguen siendo útiles en ciertos contextos. Además, la elección metodológica depende del tamaño y la frecuencia de los datos. La evidencia respalda la superioridad de la IA, aunque persisten desafíos en interpretabilidad y eficiencia computacional.

Caso de estudio

La figura 1 presenta la serie de tiempo del recaudo web desde el 2018 al 2023, en este caso la serie muestra unos valores incrementales desde el año 2022, alcanzando sus máximos picos de recaudo en el año 2023.




Figura 1. Serie de tiempo completa del recaudo web.
Elaboración autor.

En la figura 2 se presenta la función de autocorrelación parcial (PACF) de la serie de valores de recaudo web desde 2018 a 2023, donde se muestra una fuerte dependencia en el primer rezago y una ligera influencia en los rezagos 2 y 3, la cual se disipa rápidamente a partir del cuarto rezago. Esto indica que la serie temporal presenta una memoria de corto plazo, donde los pagos actuales dependen principalmente del mes inmediatamente anterior y, en menor medida, de los dos meses previos. En consecuencia, la estructura sugiere que un modelo autoregresivo de bajo orden, como un AR(1) o AR(2), podría capturar adecuadamente la dinámica de la serie.




Figura 2. Autocorrelación parcial de la serie de recaudo web. Elaboración autor.

La figura 3 presenta la división de la serie de tiempo para la aplicación de los modelos de aprendizaje profundo en tres momentos conjuntos de entrenamiento, validación y prueba, lo cual representa el 60%, 20% y 20% respectivamente.




Figura 3. Separación del dataset de recaudo web.
Elaboración autor.

Métricas de desempeño

Las métricas de desempeño utilizadas para evaluar los modelos de aprendizaje profundo y redes neuronales son el MAPE y el RMSE, esto a que ofrecen visiones complementarias del error, por ejemplo el MAPE (error promedio porcentual absoluto) muestra la precisión relativa en porcentaje, lo que facilita comparar resultados y entender qué tan lejos están las predicciones de los valores reales del recaudo, mientras que el RMSE (raíz del error cuadrático medio) mide la magnitud absoluta de los errores en las mismas unidades de la variable, penalizando con más fuerza los fallos grandes. Estas dos métricas al usarlas en conjunto permite evaluar tanto la consistencia del modelo en términos relativos como su capacidad para evitar desviaciones críticas en la escala real de los datos.

Referencias

- Abedin, M. Z., Chi, G., Uddin, M. M., Satu, Md. S., Khan, Md. I., & Hajek, P. (2021). Tax Default Prediction Using Feature Transformation-Based Machine Learning. *IEEE Access*, 9, 19864–19881. <https://doi.org/10.1109/ACCESS.2020.3048018>
- Abouzaid, O., & Boussedra, F. (2025). Artificial intelligence and exchange rate forecasting: assessing predictive accuracy and macroeconomic sensitivity. *Frontiers in Applied Mathematics and Statistics*, 11. <https://doi.org/10.3389/fams.2025.1654093>
- Battiston, P., Gamba, S., & Santoro, A. (2024). Machine learning and the optimization of prediction-based policies. *Technological Forecasting and Social Change*, 199. <https://doi.org/10.1016/j.techfore.2023.123080>
- Chang, E., Gueorguiev, N., Gavin, E., & Honda, J. (2020). Raising Tax Revenue: How to Get More from Tax Administrations? *International Monetary Fund (IMF) Research Paper Series*.
- Charef, F. (2024). *A comparison of feed forward and recurrent neural networks in time series forecasting*. <https://doi.org/10.21203/rs.3.rs-4022444/v1>
- David, R., & Wasesa, M. (2022). Machine Learning Analytics for Predicting Tax Revenue Potential. *Indonesian Treasury Review*, 7(3), 193–205. <https://doi.org/10.33105/itrev.v7i3.497>
- Inzirillo, H. (2024). *Deep State Space Recurrent Neural Networks for Time Series Forecasting*.
- Varshney, R. (2025). Leveraging technology to enhance tax collection: a study of Indian government initiatives. *Recent Trends and Innovation in Commerce and Economics*, 100–121. <https://doi.org/10.51767/ic250108>
- Wang, Y.-F., Wang, M. Y.-F., & Tu, L.-Y. (2025). An Evaluation of Machine Learning Models for Forecasting Short-Term U.S. Treasury Yields. *Applied Sciences*, 15(12), 6903. <https://doi.org/10.3390/app15126903>
- Zou, X., Wang, K., Lu, J., & Wu, D. (2024). Time series forecasting of emission trends using recurrent neural networks. *Computer Life. Computer Life*, 12(3), 12–20.