

Aplicación del aprendizaje profundo en la predicción de series de tiempo del recaudo: Caso de estudio en el distrito de Medellín

Application of deep learning in time series prediction of tax collection: Case study in the district of Medellín

Julián Alberto Uribe Gómez
0000-0001-8581-0376
Julian.uribe3@udea.edu.co

Resumen

Se analiza la aplicación de técnicas de aprendizaje profundo para la predicción de series de tiempo del recaudo tributario web en Medellín entre 2018 y 2023. Se utilizó un conjunto de 44682 datos provenientes de la Subsecretaría de Tesorería, aplicando modelos tradicionales y de aprendizaje profundo, combinando métricas para evaluar precisión y robustez de los modelos. Los resultados preliminares evidencian dependencia temporal de corto plazo y una base potencial de datos para la aplicación de los modelos, con el fin de apoyar la asignación eficiente de recursos, mejorar la gestión tributaria y fortalecer las decisiones administrativas basada en datos.

Palabras clave: aprendizaje profundo, recaudo tributario, series de tiempo, predicción

Abstract

This study analyzes the application of deep learning techniques for predicting time series data on online tax collection in Medellín between 2018 and 2023. A dataset of 44,682 data points from the Treasury Sub-Secretariat was used, applying both traditional and deep learning models and combining metrics to evaluate model accuracy and robustness. Preliminary results show short-term time dependence and a potential database for applying these models to support efficient resource allocation, improve tax management, and strengthen data-driven administrative decisions.

Keywords: Deep learning, tax collection, time series, prediction

1. Introducción

El recaudo de impuestos es el proceso gubernamental de obtener ingresos de los contribuyentes para financiar los servicios y proyectos públicos de orden nacional, departamental y municipal, constituyendo un componente vital de la gobernanza económica (Varshney, 2025). Por esta razón, predecir el recaudo de impuestos es crucial para optimizar la asignación de recursos públicos, prevenir incumplimientos fiscales y maximizar los ingresos gubernamentales mediante intervenciones focalizadas y una mayor eficiencia administrativa.

Predecir la recaudación tributaria es esencial por numerosas razones que van más allá de la mera gestión fiscal. Una previsión precisa permite a los gobiernos planificar estratégicamente sus presupuestos y asignar recursos de forma eficiente, lo que a su vez fomenta la estabilidad económica y el crecimiento. Los ingresos fiscales son cruciales para financiar servicios públicos como la educación, la sanidad y la infraestructura, fundamentales para el desarrollo de un país. Las implicaciones de una previsión eficaz de la recaudación tributaria pueden influir significativamente en el panorama económico, especialmente en las economías en desarrollo, donde la recaudación tributaria suele verse limitada.

En primer lugar, una previsión precisa de la recaudación tributaria puede mejorar el cumplimiento y fomentar las contribuciones voluntarias. Metodologías sólidas, como la economía del comportamiento y el análisis de big data, ayudan a las autoridades fiscales a comprender el comportamiento y la motivación de los contribuyentes, mejorando así las tasas de cumplimiento. Cuando los contribuyentes perciben que sus contribuciones se gestionan y utilizan eficazmente, es más probable que cumplan, como destacan Putra et al. (2024) quienes afirman que la socialización fiscal fomenta una cultura de comprensión de las regulaciones tributarias, lo que mejora el cumplimiento voluntario. Además, la comunicación efectiva de los beneficios fiscales incentiva a los ciudadanos a cumplir con sus obligaciones, lo que conduce a un aumento de los ingresos fiscales Umar (2024).

La evidencia es sólida a lo largo de múltiples estudios y metodologías. Tres estudios entre 2021 y 2024 demuestran de manera consistente el valor de los sistemas de predicción tributaria y como los enfoques de aprendizaje automático, superan de manera consistente a los métodos tradicionales en múltiples estudios (Abedin et al., 2021; Battiston et al., 2024; David & Wasesa, 2022). Chang et al. (2020) aportan evidencia cuantitativa de que los países con mayor fortaleza operativa en la administración tributaria recaudan 3.25% más del producto interno bruto en ingresos fiscales. Las implicaciones de política incluyen una mejor asignación de recursos para auditorías, intervención temprana ante posibles incumplidores, gestión mejorada del riesgo de cumplimiento y toma de decisiones basada en datos que puede incrementar sustancialmente los ingresos mientras promueve una tributación equitativa (Battiston et al., 2024).

En ese sentido, diferentes autores han probado diversos métodos de pronóstico. Thayyib et al. (2023) descubrieron que el modelo híbrido Theta-TBATS ofrecía una precisión de pronóstico superior para los ingresos tributarios, siendo el TBATS individual el segundo con mejor rendimiento, superando a los modelos ARIMA y de redes neuronales tradicionales. Por otro lado, Pebriani Wahyu et al. (2022) demostraron que el método aditivo de Winters alcanzó un 14 % de error porcentual absoluto medio al pronosticar los ingresos tributarios locales. Otros autores como Ofori et al. (2020) demostraron que el modelo ARIMA con intervención superó a los métodos de tendencia lineal de Holt para el pronóstico de los ingresos del IVA. Finalmente, Simonov & Gligorov (2021) descubrieron que los métodos de conjunto que combinan modelos estadísticos y aprendizaje automático mejoraron la precisión del pronóstico en comparación con los enfoques individuales y tradicionales.

En este sentido, esta entrega busca desarrollar y evaluar un conjunto de modelos basado en técnicas de aprendizaje profundo para la predicción de series de tiempo del recaudo tributario en el distrito de Medellín, con el fin de optimizar la asignación de recursos públicos y apoyar la toma de decisiones orientadas a incrementar la eficiencia en la administración tributaria.

2. Marco conceptual

Las investigaciones actuales en predicción de series de tiempo destacan la limitada capacidad de los modelos econométricos tradicionales, como ARIMA, para capturar fenómenos de no linealidad y volatilidad de algunos conjuntos de datos, en especial los financieros. Para superar estas limitaciones, se han explorado técnicas de inteligencia artificial, en particular redes neuronales recurrentes (RNN) y perceptrones multicapa (MLP), en conjunto con métodos como los bosques aleatorios (RF).

Charef (2024) analizó los tipos de cambio USD/NOK y USD/EUR (con espacio de tiempo desde 2017 a 2022, 1305 observaciones), comparando redes MLP y RNN mediante el Error Cuadrático Medio (MSE). Los resultados confirmaron que las RNN ofrecieron mayor precisión y robustez. Por su parte, Wang et al. (2025) evaluaron la rentabilidad de los bonos del Tesoro de EE. UU. a 10 años empleando regresión lineal, árbol de decisión, bosque aleatorio y MLP. Con métricas como MSE,

MAE y R^2 , el bosque aleatorio fue el modelo más exacto, logrando $R^2 = 0,576$ y confirmando la eficacia de los enfoques de aprendizaje de máquina en macro finanzas.

En el ámbito del mercado cambiario, Abouzaid & Boussedra (2025) usaron datos mensuales del EUR/USD (con espacio de tiempo desde 2014 a 2024, 120 observaciones) junto con variables macroeconómicas. Compararon MLP, bosque aleatorio y LSTM, mostrando que este último alcanzó la mejor precisión ($R^2 = 0,9234$). Sin embargo, las variables macroeconómicas aportaron escaso valor explicativo para los errores de predicción.

Por otro lado, Inzirillo (2024) analizó el mercado de criptoactivos y propuso un enfoque híbrido que combina modelos de espacio de estados y arquitecturas RNN (tales como LSTM y GRU), lo cual mejoró la adaptabilidad a regímenes de mercado volátiles. Finalmente, Zou et al. (2024) aplicaron RNN a la predicción de emisiones, demostrando que las LSTM superan ampliamente a ARIMA y al suavizado exponencial.

Finalmente, los estudios concluyen que las RNN, en especial las LSTM, superan a modelos clásicos y redes superficiales, mientras que los métodos de aprendizaje de máquina siguen siendo útiles en ciertos contextos. Además, la elección metodológica depende del tamaño y la frecuencia de los datos. La evidencia respalda la superioridad de la IA, aunque persisten desafíos en interpretabilidad y eficiencia computacional.

2.1. Métricas de desempeño

Las métricas de desempeño utilizadas para evaluar los modelos de aprendizaje profundo y redes neuronales en este entregable comparativo son las siguientes: RMSE, MAPE, MAE, sMAPE, MASE y R^2 , todas estas métricas ofrecen visiones complementarias del error, en este caso el MAPE (promedio del error absoluto) muestra la precisión relativa en porcentaje, lo que facilita comparar resultados, mientras que el RMSE (raíz cuadrada del promedio de los errores al cuadrado) mide la magnitud absoluta de los errores en las mismas unidades de la variable, penalizando con más fuerza los fallos grandes. El MAE (error absoluto medio) refleja el error promedio en términos absolutos y es más robusto ante valores atípicos, el sMAPE (error porcentual absoluto medio simétrico) ajusta el MAPE para evitar distorsiones cuando los valores reales son cercanos a cero, y el MASE (error absoluto escalado medio) permite comparar el desempeño del modelo frente a un modelo de referencia, lo que resulta útil para validar mejoras. Finalmente, el R^2 (coeficiente de determinación) indica la proporción de la variabilidad de los datos explicada por el modelo, siendo una métrica de ajuste global.

En conjunto, estas métricas permiten evaluar la precisión, robustez, comparabilidad, consistencia y capacidad explicativa de los modelos de redes neuronales y aprendizaje profundo en términos relativos como su capacidad para evitar desviaciones críticas en la escala real de los datos en las tareas de predicción.

3. Metodología

La tabla 1 presenta los detalles sobre el conjunto de datos de estudio. Para predecir el recaudo web mediante modelos de aprendizaje profundo y redes neuronales se procesó un conjunto de 44682 datos agrupados por fechas y horas desde el año 2018 al 2023. Dicha información pertenece a la Secretaría de Hacienda de Medellín, quienes disponen de la información a través de sus sistemas de información.

Tabla 1. Detalles del dataset de recaudo. Elaboración autor.

Variab les	1. Fecha_Hora (año-mes-día Hora) 2. Valor Pago
Tipo de datos	1. Fecha_Hora: datetime 2. Valor Pago: float64
Número de datos	44682 registros
Espacio temporal	Enero 2018 – Diciembre 2023
Categoría	Transacciones web
Fuente de datos	Secretaría de hacienda – Subsecretaría de tesorería Alcaldía de Medellín
Método	Modelos de redes neuronales LSTM RNN
Entrenamiento y validación de los modelos	80/20

3.1. Arquitectura de los modelos

La tabla 2 presenta la arquitectura propuesta para los modelos de predicción de recaudo, por lo tanto, la tarea asignada para cada red es regresión. Se eligen 3 modelos RNN, LSTM y GRU, con un look_back de 10 constante para todos los modelos, un dropout variable, pero recomendado de 0.3 para evitar el sobre ajuste. Cada modelo cuenta con 3 capas y con un número variable de unidades en cada capa, excepto en la capa de salida la cual es una unidad.

Tabla 2. Arquitectura de los modelos propuestos. Elaboración autor.

Característica	RNN	LSTM	GRU
Entrada	(look_back, 1)	(look_back, 1)	(look_back, 1)
Capas ordenadas	SimpleRNN (units) - Dropout(rate=Dropout) – Dense (1)	LSTM (units) - Dropout(rate=Dropout) - Dense (1)	GRU (units) - Dropout(rate=Dropout) – Dense (1)
Activaciones	tanh (SimpleRNN), linear (Dense)	tanh (estado), sigmoid (puertas), linear (Dense)	tanh (candidato), sigmoid (puertas), linear (Dense)
Salida	Escalar (1)	Escalar (1)	Escalar (1)
Tarea	Regresión	Regresión	Regresión
Pérdida	MSE	MSE	MSE
Optimizador	adam	adam	adam

4. Resultados

La figura 1 presenta la serie de tiempo del recaudo web desde el 2018 al 2023, en este caso la serie muestra unos valores incrementales desde el año 2022, alcanzando sus máximos picos de recaudo en el año 2023.




Figura 1. Serie de tiempo completa del recaudo web. Elaboración autor.

En la figura 2 se presenta la función de autocorrelación parcial (PACF) de la serie de valores de recaudo web desde 2018 a 2023, donde se muestra una fuerte dependencia en el primer rezago y una ligera influencia en los rezagos 2 y 3, la cual se disipa rápidamente a partir del cuarto rezago. Esto indica que la serie temporal presenta una memoria de corto plazo, donde los pagos actuales dependen principalmente del mes inmediatamente anterior y, en menor medida, de los dos meses previos. En consecuencia, la estructura sugiere que un modelo autorregresivo de bajo orden, como un AR(1) o AR(2), podría capturar adecuadamente la dinámica de la serie.




Figura 2. Autocorrelación parcial de la serie de recaudo web. Elaboración autor.

Al aplicar los diferentes modelos de aprendizaje profundo y tradicionales, se observan los diferentes acercamientos predictivos. La figura 3a y la figura 3b muestran los resultados en la predicción utilizando tratamientos tradicionales como media móvil y EWMA, mientras que la figura 3c y 3d muestran los acercamientos utilizando RNN y LSTM.




Figura 3. Resultados de los modelos comparados. Elaboración autor.

Tabla 3. Resultados de las métricas de ellos modelos. Elaboración autor.

Modelo	Configuración	RMSE	MAPE	MAE	sMAPE	MASE	R ²
LSTM	Units=100, Epoch=50	866,355,038.74	68,283.24%	194,783,443.85	129.26%	1.63	0.225
RNN	Units=50, Epoch=150	874,139,011.07	44,094.28%	198,326,727.12	97.08%	1.66	0.211
Media móvil	–	572,096,551.13	105,804.73%	186,288,841.45	114.99%	1.18	0.09
LSTM	Units=50, Epoch=100	881,378,485.45	101,117.73%	178,474,667.23	98.62%	1.49	0.198
LSTM	Units=50, Epoch=50	876,904,390.72	283,911.37%	206,376,614.74	111.61%	1.73	0.206
LSTM	Units=50, Epoch=150	881,598,294.15	185,872.80%	192,577,150.76	103.30%	1.61	0.197
RNN	Units=50, Epoch=50	895,840,671.25	153,068.19%	202,701,057.80	107.55%	1.69	0.171
RNN	Units=100, Epoch=50	898,659,896.53	235,115.17%	209,690,649.97	113.27%	1.75	0.166
RNN	Units=50, Epoch=100	890,697,441.13	392,418.47%	227,093,276.45	121.75%	1.90	0.181
EWMA	–	868,235,301.97	307,014.92%	267,879,940.88	115.39%	1.07	0.21

Al analizar los resultados obtenidos y presentados en la tabla 3, se observa que el modelo LSTM con 100 unidades y 50 épocas presenta el mejor desempeño general, ya que combina un bajo RMSE y MAE con el mayor valor de R², lo que evidencia una mayor capacidad explicativa en la predicción de la serie temporal del recaudo web. El modelo RNN con 50 unidades y 150 épocas también muestra un comportamiento competitivo, destacándose por alcanzar los valores más bajos de MAPE y sMAPE, lo cual indica una adecuada precisión relativa, aunque con un RMSE ligeramente superior. En contraste, el método de media móvil sorprende al lograr errores absolutos bajos y un MASE cercano a 1, lo que refleja un buen ajuste en términos relativos, aunque su baja capacidad explicativa limita su utilidad predictiva. Por otra parte, algunos modelos de LSTM y RNN exhiben resultados intermedios con métricas aceptables, pero con valores de MAPE elevados que afectan su consistencia. Finalmente, el modelo EWMA, a pesar de obtener un R² relativamente alto y un MASE favorable, se posiciona entre los de menor rendimiento debido a un MAPE excesivamente elevado, lo cual compromete su aplicabilidad práctica. En conjunto, la evidencia sugiere que los modelos basados en redes neuronales, particularmente LSTM y RNN en configuraciones específicas, ofrecen ventajas significativas frente a los métodos tradicionales, aunque su desempeño depende fuertemente de la correcta calibración de parámetros.

5. Conclusiones

Se puede afirmar con cautela que los modelos de aprendizaje profundo (como RNN y LSTM) presentan un potencial superior en la predicción de series de tiempo frente a los modelos tradicionales (media móvil, EWMA), pero esta superioridad no es absoluta ni garantizada en todos los contextos.

En comparación, los LSTM y RNN alcanzan en varias configuraciones mejores métricas de ajuste, especialmente en términos de R^2 , MAPE y sMAPE, lo que indica una mayor capacidad de capturar patrones complejos, no lineales y dependencias temporales de mayor alcance. Sin embargo, también se observa que algunos ajustes de parámetros producen resultados poco consistentes, con errores porcentuales muy elevados, lo que revela una alta sensibilidad a la calibración y al riesgo de sobreajuste.

Por el contrario, los métodos tradicionales como la media móvil o el EWMA muestran un desempeño más estable, con menores errores absolutos en ciertos casos y menor complejidad computacional, aunque con una capacidad explicativa reducida y limitaciones para adaptarse a dinámicas no lineales.

En consecuencia, se puede concluir que los modelos de aprendizaje profundo ofrecen ventajas significativas en escenarios donde existen patrones no lineales y estructuras temporales complejas, pero su efectividad depende de la disponibilidad de datos suficientes, la adecuada selección de hiper parámetros y la validación rigurosa de resultados. En ausencia de estas condiciones, los modelos tradicionales pueden seguir siendo una alternativa válida y más robusta.

Sin embargo, la evidencia está limitada por el alcance geográfico (principalmente países en desarrollo) y los diferentes horizontes de pronóstico. La mayoría de los estudios se centran en pronósticos a corto plazo en lugar del período específico de cinco años solicitado.

6. Referencias

- Abedin, M. Z., Chi, G., Uddin, M. M., Satu, Md. S., Khan, Md. I., & Hajek, P. (2021). Tax Default Prediction Using Feature Transformation-Based Machine Learning. *IEEE Access*, 9, 19864–19881. <https://doi.org/10.1109/ACCESS.2020.3048018>
- Abouzaid, O., & Boussedra, F. (2025). Artificial intelligence and exchange rate forecasting: assessing predictive accuracy and macroeconomic sensitivity. *Frontiers in Applied Mathematics and Statistics*, 11. <https://doi.org/10.3389/fams.2025.1654093>
- Battiston, P., Gamba, S., & Santoro, A. (2024). Machine learning and the optimization of prediction-based policies. *Technological Forecasting and Social Change*, 199. <https://doi.org/10.1016/j.techfore.2023.123080>
- Chang, E., Gueorguiev, N., Gavin, E., & Honda, J. (2020). Raising Tax Revenue: How to Get More from Tax Administrations? *International Monetary Fund (IMF) Research Paper Series*.
- Charef, F. (2024). *A comparison of feed forward and recurrent neural networks in time series forecasting*. <https://doi.org/10.21203/rs.3.rs-4022444/v1>
- David, R., & Wasesa, M. (2022). Machine Learning Analytics for Predicting Tax Revenue Potential. *Indonesian Treasury Review*, 7(3), 193–205. <https://doi.org/10.33105/itrev.v7i3.497>
- Inzirillo, H. (2024). *Deep State Space Recurrent Neural Networks for Time Series Forecasting*.
- Ofori, M. S., Fumey, A., & Nketiah-Amponsah, E. (2020). Forecasting Value Added Tax Revenue in Ghana. *Journal of Economics and Financial Analysis*, 4(2), 63–99. <https://doi.org/10.1991/jefa.v4i2.a37>
- Pebriani Wahyu, F., Dwi Rahmawati, I., & Umam, K. (2022). Identifying Best Method for Forecasting Tax Income using Time Series Analysis. *Iapa Proceedings Conference*, 60. <https://doi.org/10.30589/proceedings.2022.683>
- Putra, D. A., Aprila, N., Pratana, P., & Herawansyah. (2024). Building a Culture of Compliance: The Influence of Tax Socialization and Inclusion on Indonesian Micro, Small, and Medium Enterprises (MSMEs) Taxpayers. *Open Access Indonesia Journal of Social Sciences*, 7(6), 1881–1893. <https://doi.org/10.37275/oaijs.v7i6.277>

- Simonov, J., & Gligorov, Z. (2021). Customs Revenues Prediction Using Ensemble Methods (Statistical Modelling vs Machine Learning). *World Customs Journal*, 15(2). <https://doi.org/10.55596/001c.116452>
- Thayyib, P. V., Thorakkattle, M. N., Usmani, F., Yahya, A. T., & Farhan, N. H. S. (2023). Forecasting Indian Goods and Services Tax revenue using TBATS, ETS, Neural Networks, and hybrid time series models. *Cogent Economics & Finance*, 11(2). <https://doi.org/10.1080/23322039.2023.2285649>
- Umar, J. (2024). Tax law and its implications for people's welfare. *Journal of Social Research*, 3(3). <https://doi.org/10.55324/josr.v3i3.1967>
- Varshney, R. (2025). Leveraging technology to enhance tax collection: a study of Indian government initiatives. *Recent Trends and Innovation in Commerce and Economics*, 100–121. <https://doi.org/10.51767/ic250108>
- Wang, Y.-F., Wang, M. Y.-F., & Tu, L.-Y. (2025). An Evaluation of Machine Learning Models for Forecasting Short-Term U.S. Treasury Yields. *Applied Sciences*, 15(12), 6903. <https://doi.org/10.3390/app15126903>
- Zou, X., Wang, K., Lu, J., & Wu, D. (2024). Time series forecasting of emission trends using recurrent neural networks. *Computer Life*, 12(3), 12–20.